

FireGuardian V2 研发技术总结报告

基于 YOLO + 规则引擎 + DeepSeek Tool-Calling Agent 的智能火灾监控系统

目录

1. 目录
2. 第一章：项目概述
3. 第二章：总体系统架构
4. 第三章：V1 阶段
5. 第四章：V1 数据集审计与模型实验
6. 第五章：V1 问题发现与工程修复
7. 第六章：V2 为什么需要 Agent
8. 第七章：Phase 1 —— DeepSeek Agent Core
9. 第八章：Phase 2 —— Hybrid Agent
10. 第九章：Thinking A/B 实验
11. 第十章：Phase 2.1 —— Agent 稳定性修复
12. 第十一章：Phase 3-A —— Agent Memory
13. 第十二章：Phase 3-B —— Agent + Memory
14. 第十三章：真实烟花困难场景
15. 第十四章：Phase 4-A —— Runtime + M10
16. 第十五章：Phase 4-B —— M11 GUI
17. 第十六章：Phase 5 —— V2 模型优化
18. 第十七章：Phase 6 —— Agent + YOLO 联合测试
19. 第十八章：V2.7 —— 最终闭环演示
20. 第十九章：最终系统功能
21. 第二十章：最终技术栈
22. 第二十一章：项目测试与验收体系
23. 第二十二章：项目目前存在的问题
24. 第二十三章：后续优化路线
25. 第二十四章：最终验收结论
26. 附录 A：版本演进
27. 附录 B：测试报告索引（仅列真实存在文件）
28. 附录 C：重要测试视频
29. 附录 D：模型版本
30. 附录 E：关键截图索引

FireGuardian V2 研发技术总结报告

项目名称: FireGuardian V2 —— 基于 YOLO + 规则引擎 + DeepSeek Tool-Calling Agent 的智能火灾监控系统

文档版本: v2.0 (最终封板版)

日期: 2026-08-16

代码分支: v2-deepseek-agent (基于 main @ 0eca3ad)

版本标签: v0.1.0-baseline (V1 稳定基线) ; v0.2.0-agent (V2 封板, Stage B 待执行)

目录

1. 项目概述
 2. 总体系统架构
 3. V1 阶段
 4. V1 数据集审计与模型实验
 5. V1 问题发现与工程修复
 6. V2 为什么需要 Agent
 7. Phase 1: DeepSeek Agent Core
 8. Phase 2: Hybrid Agent
 9. Thinking A/B 实验
 10. Phase 2.1: Agent 稳定性修复
 11. Phase 3-A: Agent Memory
 12. Phase 3-B: Agent + Memory
 13. 真实烟花困难场景
 14. Phase 4-A: Runtime + M10
 15. Phase 4-B: M11 GUI
 16. Phase 5: V2 模型优化
 17. Phase 6: Agent + YOLO 联合测试
 18. V2.7: 最终闭环演示
 19. 最终系统功能
 20. 最终技术栈
 21. 项目测试与验收体系
 22. 项目目前存在的问题
 23. 后续优化路线
 24. 最终验收结论
- 附录 A: 版本演进
- 附录 B: 测试报告索引

附录 C：重要测试视频

附录 D：模型版本

附录 E：关键截图索引

第一章：项目概述

FireGuardian 是一个基于计算机视觉、规则决策与大语言模型 Agent 的智能火灾监控系统。

项目目标：以 YOLO 视觉检测为核心感知，以事件聚合（M6）与规则引擎（M7）为确定性安全底座，在此基础上引入 DeepSeek Agent 与历史记忆，形成「看得见、判断得清、解释得明、可审计」的智能火灾监控闭环。

应用场景：室内外火灾监控视频流 / 图片集；烟、火、烟花、雾、蒸汽、强光等易混淆场景的识别与复核；需要人工复核与过程留痕的安防场景。

核心问题：

- 单纯 YOLO 检测存在误报（烟花/强光/夜间灯光）与漏报（淡烟/小目标）；
- 规则引擎 M7 确定但缺少上下文解释，无法回答「为什么是这个等级」；
- 检测结果孤立，无法利用历史事件辅助当前判断；
- 引入 LLM 后必须保证安全底线（M7 High 不可被降级、失败可回退）。

V1 → V2 演进路线：

V1: YOLO → M6 → M7 → M8 → M9 → M10 → M11
V2: YOLO → M6 → M7 → DeepSeek Agent → Tool Calling → Agent Memory
→ Hybrid Decision → Presentation Model → M10 → M11


第二章：总体系统架构

2.1 V1 架构

YOLO11n (fire / smoke)
↓
M3 / M4 / M5 图片检测 / 视频检测 / 模拟验证流
↓
M6 EventAggregator (FireEvent: 秒制时长、union area 面积特征)
↓
M7 FireDecisionAgent (规则评分 + 硬性覆盖)
↓
M8 Screenshot (confirmed / peak / upgrade / final)
↓
M9 Logs (events.jsonl / application.log)
↓
M10 Report (report.md / report.pdf)
↓
M11 GUI (PyQt6)

2.2 V2 架构

YOLO11n (V2-15k, fire / smoke)
↓
M6 FireEvent



第三章：V1 阶段

V1 按 M1~M11 模块化实现，覆盖数据、训练、检测、聚合、决策、截图、日志、报告与 GUI 全链路。

模块	职责
M1	项目基础设施、配置 (config.yaml) 、统一路径管理 (PathManager)
M2	YOLO 训练器 (YOLOTrainer) 、冒烟训练、Baseline V1 训练与评估
M3	图片检测 (fire/smoke 识别)
M4	视频检测 (逐帧 decode)
M5	模拟验证流 (事件输入)
M6	FireEvent 事件聚合：状态机 CANDIDATE→CONFIRMED→ACTIVE→ENDED，面积与秒制时间特征
M7	规则风险决策 (评分 + 硬性覆盖，输出 level/score/confidence/reasons)
M8	证据截图 (confirmed/peak/upgrade/final)
M9	JSONL 日志 (events.jsonl，含敏感字段脱敏)
M10	报告生成 (md + pdf)
M11	PyQt6 GUI (左侧数据源 / 中央画面 / 右侧信息 / 事件历史 / 训练 / 日志)

M6 阶段实际发现并记录了两个关键问题（详见第五章）：bbox 重叠导致面积重复统计、frame_id 与 seconds 混用。

第四章：V1 数据集审计与模型实验

4.1 数据集审计

对 F:\火焰数据集\Dataset (train/valid/test) 全量审计 (105,257 张)：

指标	数值
总图片 / 标签	105,257 / 105,257
空标签 (负样本)	41,620
fire 图	37,367

指标	数值
smoke 图	48,784
fire+smoke 图	22,514
越界框图片	319
SHA-256 完全重复（跨集合）	1,706 组 / 3,412 个文件
pHash 近似重复对	636,434 对
抽样跨集合相邻帧	30 组抽样中 24 组疑似相邻视频帧

结论：数据量充足，但存在跨集合重复/近似重复导致的数据泄漏风险，训练/验证指标可能偏乐观；正式实验前需去重并重新划分。

4.2 冒烟模型 (Smoke V1)

```
train=3000 val=600 epochs=3 YOLO11n
```

主要作用：验证 M2 训练链路与 models/best.pt 产出，确认完整系统链路可运行。

4.3 Baseline V1

```
train=15000 val=3000 test=3000 epochs=30 YOLO11n
```

独立 Test 结果 (conf=0.25)：

指标	数值
Precision	0.7313
Recall	0.6533
mAP50	0.7352
mAP50-95	0.4557
fire AP50	0.6942
smoke AP50	0.7761

Baseline V1 替代冒烟模型成为 V1 正式默认模型 (models/best.pt)。

第五章：V1 问题发现与工程修复

问题 1：bbox 面积重复统计

现象：同一类别多个 bbox 重叠时，简单求和导致 fire_area / smoke_area 被重复计算，事件特征失真。

分析：面积应基于并集而非框面积之和。

方案与实现：同类别 bbox 计算 union area，再归一化为 fire_area_ratio / smoke_area_ratio。

验证：M6 回归测试覆盖单框、分离框、完全重叠、包含、部分重叠等用例，全部通过。

问题 2：frame_id 与 seconds 混用

现象：部分时长判断把 frame_id 当作秒使用，事件时长失真。

方案与实现：统一秒制基准 duration_seconds，frame_id 通过 frame_id / fps 转换为秒。

验证：M7 决策统一使用秒制字段；test_m6_m7_fix 回归通过。

问题 3: GUI / Agent 链路失败可回退

现象: 决策链路一旦异常, 界面与下游模块可能中断。

方案与实现: Fallback = M7 规则决策; M8/M9/M10/M11 对失败容错。

验证: V1 全链路回归通过。

第六章: V2 为什么需要 Agent

V1 的 M7 是规则引擎, 不是真正的 LLM Agent: 它按固定权重与阈值输出等级, 无法理解事件上下文、无法解释原因、无法利用历史证据。

V2 引入 DeepSeek Agent、Tool Calling、Memory 与 Hybrid, 但保留 M7 作为确定性安全底座, 而不是「LLM 替代 M7」:

M7 负责安全 (确定性规则, 永不被降级)
LLM 负责分析 (理解、解释、复核、历史查询、建议)
Hybrid 负责融合 (安全单调性 + 审计记录)

关键原则: LLM 不替代 YOLO (不重新识别图片)、不替代 M7 (不直接改等级)、不能降低 M7 High、失败必须回退 M7。

第七章: Phase 1 —— DeepSeek Agent Core

技术: DeepSeek V4 Flash (deepseek-v4-flash)、OpenAI 兼容 API、JSON Output、Tool Calling、Schema Validation、Retry / Timeout、Fallback、.env 密钥隔离。

实际工作 (真实研发过程):

- 1. 实现 DeepSeekClient、EventContext、ToolRegistry、ToolExecutor、Schemas、Prompts;
- 2. 首次 Agent Loop 真实测试时发现: V4 Flash 默认 thinking 模式消耗大量 completion 预算, 导致第二轮 JSON 输出失败 (非法 JSON: 未终止字符串);
- 3. 进一步诊断 (第二轮 max_tokens 降为 768) 发现 finish_reason=length、completion_tokens=768 打满、raw_content_length=0——模型把预算耗在推理阶段;
- 4. 修复: Agent Loop 改为 non-thinking (thinking=disabled), 最终输出轮不带 tools 并设置 tool_choice=none, max_tokens=768, 保留 Schema Validation 与 Fallback;
- 5. 重新测试通过。

测试: Phase 1 最终 66/66 (含 V1 回归 12 项); 真实 API 冒烟 PASS。

第八章: Phase 2 —— Hybrid Agent

实现: FireGuardianLLMAgent (≤3 轮 Tool Calling + 最终严格 JSON)、HybridDecisionCoordinator、AgentStatus (ok/unavailable/invalid_output)、should_call_agent 调用时机控制。

Hybrid 安全规则 (Case 1~7):

Case	M7	Agent	Final	requires_review
1	high	low	high	false

Case	M7	Agent	Final	requires_review
2	high	high	high	false
3	medium	high	high	true
4	medium	medium	medium	false
5	low	high	high	true
6	any	unavailable	= M7	false
7	any	invalid_output	= M7	false

真实测试记录：

M7 high + Agent low → high (M7 High 不可降级)
M7 medium + Agent high → high + requires_review
Agent unavailable → M7
Agent invalid_output → M7

测试：Phase 2 总计 97/97 (Phase 1 66 + 新增 31) 。

第九章：Thinking A/B 实验

6 个固定案例 × 2 模式 (thinking disabled / enabled) ：

指标	disabled	enabled
与 M7 等级对齐率	6/6	3/6
平均延迟	约 8.8s	约 15.6s
Token 总量	33,879	34,911
成功率	6/6	6/6

结论：当前 FireGuardian 采用 thinking disabled。这是基于当前固定测试集得到的工程决策，不声称 thinking 模式普遍更差。

第十章：Phase 2.1 —— Agent 稳定性修复

问题：真实 API 中模型偶发把 agent_assessment 输出为 CONFIRMED（与事件状态 status 混淆、或缩写 CONFIRMED_RISK），触发 Schema 失败。

修复：

- 三个 Prompt (system / event_analysis / final_output) 强化枚举取值与反例；
- 新增 agent/display_text.py：空字段展示 fallback（暂无明确判断 / 无引用证据 / 未给出处置建议 ...），不修改原始 AgentResult；
- AgentResult 可选字段向后兼容。

测试：Phase 2.1 总计 101/101。

第十一章：Phase 3-A —— Agent Memory

实现：

- memory_models.py: EventMemoryRecord / MemoryConfig / SimilarEvent / MemorySearchResult;

- memory_normalizer.py: 字段兼容 (duration/duration_seconds、max_*_area_ratio、avg_*_confidence) 、枚举标准化、坏记录跳过;
- memory_retriever.py: 结构化加权相似度 (8 特征, 权重合计 1.00) 、top_k、阈值、排序;
- agent_memory.py: 只读加载 + mtime 缓存 + M7 决策 join + MemoryToolDataSource;
- get_similar_events 重新启用 (event_id / top_k 1~10 / min_similarity 0~1) 。

关键约束: 默认只检索已结束历史事件; 当前事件按 event_id 排除; 无 Hybrid 日志时 final_level 保持 null; fixture 与真实日志分离。

说明: 第一版没有引入 Embedding / Vector DB——当前结构化事件数量有限, 结构化检索透明且足够。

测试: Phase 3-A 总计 143/143。

第十二章: Phase 3-B —— Agent + Memory

A/B 实验: 6 固定案例 × (Without Memory / With Memory) 。

重点记录:

case_02 smoke_only: Without Memory → UNCERTAIN
With Memory → SUSPICIOUS (3 个相似烟雾事件, 判断更明确)

case_03 fire_smoke: Without Memory → SUSPICIOUS
With Memory → UNCERTAIN (4 个相似事件, 更保守)

说明: Memory 不是单纯让模型风险升级, 而是提供历史证据让 Agent 重新评估; M7 High 始终不被降级; Without Memory 臂中模型偶发「幻觉调用」被白名单拦截。

测试: Phase 3-B 总计 157/157。

第十三章: 真实烟花困难场景

独立重要章节, 素材:

视频	特点
me.mp4	烟花/短时亮光+烟雾
烟花1.mp4	smoke 主导 (smoke 最大面积约 0.54, fire 约 0.03)
烟花2.mp4	fire 最大面积约 0.529 (强光误检风险) , M7=high

重点工程案例: 烟花2 中 YOLO 曾把强光误检为 fire (最大面积约 0.529、置信度 0.819) , 但:

- Agent 结合历史烟花模式判 SUSPICIOUS/UNCERTAIN, 而非 CONFIRMED_RISK;
- Memory 提供「历史相似多为短时烟雾/烟花」证据;
- Hybrid Final 始终保持 HIGH——烟花2 最终没有因为 Memory/Agent 而错误降低 M7 High。

第十四章: Phase 4-A —— Runtime + M10

实现:

- presentation_models.py: AgentPresentationModel (M10/M11 共用展示数据, 不做重算) ;

- UiController Worker 接入: DeepSeek / Memory / Tool / Hybrid 全部在独立守护线程;
- AgentTriggerGuard: confirmed / risk_upgrade / disagreement / ended 去重, 单事件 ≤ 4 次, risk_upgrade 按等级去重;
- run_agent_with_timeout: 整体超时 60s $\rightarrow$ unavailable 回退 M7, 不阻塞 M8/M9/M10/GUI;
- M10 report_generator.py: 新增 Agent Analysis 章节 (Rule / Assessment / Memory / Explanation / Cause / Action / Final / Tools), 旧事件无 Agent 数据时显示 Not available, md/pdf/event.json 三端一致。

测试: Phase 4-A 总计 173/173。

第十五章: Phase 4-B —— M11 GUI

实现:

- ui/agent_panel.py: AgentAnalysisPanel (Hybrid Final $\rightarrow$ Rule/Agent/Memory $\rightarrow$ Explanation/Cause/Action $\rightarrow$ Details 四级信息层级) ;
- 四个 Qt Signal (agent_started / agent_tool_called / agent_completed / agent_failed) 驱动状态切换 (Analyzing / Tool / Completed / Fallback / Timeout) ;
- 事件历史表新增 Rule / Agent / Final / Memory 列;
- 关闭安全: closeEvent 增加「正在停止Agent...」, Agent Worker 为 daemon, 不阻塞退出;
- 历史详情只使用该事件自身 PresentationModel, 无字段显示「未提供」。

验证: offscreen (QT_QPA_PLATFORM=offscreen) 自动化测试覆盖全状态; 真实 API + offscreen GUI 冒烟通过; 烟花2 展示 Rule HIGH / Agent UNCERTAIN / Final HIGH。

测试: Phase 4-B 总计 186/186。

第十六章: Phase 5 —— V2 模型优化

16.1 数据重划分 (消除泄漏)

- 全量扫描 105,257 张;
- 基于审计 exact_duplicates + near_duplicates (distance ≤ 8) 做 union-find 片段分组 (99,730 片段, 最大 212), 同一片段不跨集合;
- 排除越界框 288 张;
- 类别配额分配: train 15,066 / val 3,000 / test 3,000 (negative/smoke_only/fire_only/both 四类齐全且比例近似全量) ;
- 输出 datasets/v2_15k_*.txt + fire_smoke_v2_15k.yaml, 扫描缓存可复现。

16.2 困难负样本

从烟花1/烟花2/me.mp4 抽取 66 张「被误检为 fire/smoke」帧 (空标签) 并入训练集。

16.3 训练

yolo11n, 40 epochs, batch=16, imgsz=640, patience=15, seed=42
 训练时长约 4.8h; best epoch=40; val mAP50 0.294 $\rightarrow$ 0.694
 产物: models/v2_15k_best.pt (未覆盖 models/best.pt)

16.4 评估（同一 v2 test 集公平对比）

模型	mAP50	mAP50-95	P@0.25	R@0.25	负样本图级误报率 (0.25/0.4/0.5)
V1 baseline	0.7325	0.4491	0.7456	0.6419	5.63% / 3.70% / 2.61%
V2-15k	0.7161	0.4334	0.7397	0.6356	2.52% / 1.34% / 0.84%

16.5 conf 阈值结论

建议生产 conf 保持 0.50：V2 在该阈值图级误报率 0.84%（V1 同测试集 2.61%），符合误报优先策略；如需更高召回可降 0.25（误报 2.52%）。

第十七章：Phase 6 —— Agent + YOLO 联合测试

17.1 检测对比（V1 vs V2，同一视频，conf≥0.25）

视频	V1 fire 最大面积	V2 fire 最大面积	V1 fire 最大置信度	V2 fire 最大置信度	结论
烟火.mp4（真实火灾）	0.519	0.521	0.607	0.759	真实火灾保留
me.mp4（烟花）	0.140	0.009	0.671	0.525	fire 误检下降约 15 倍
烟花1.mp4	0.104	0.022	0.626	0.334	fire 误检下降约 4.6 倍
烟花2.mp4	0.781	0.349	0.819	0.482	误检下降约 2.2 倍，生产 conf=0.5 下不再触发 fire

17.2 Agent + Hybrid 联合评估（真实 API）

场景	V2 fire 面积	Agent	Agent 等级	Final	说明
real_fire（烟火.mp4）	0.521	CONFIRMED_RISK	medium	high	M7 high 保持
fireworks_me（me.mp4）	0.009	invalid_output	-	medium	Schema 失败回退 M7
fireworks1（烟花1.mp4）	0.022	UNCERTAIN	medium	medium	历史未达阈值，如实报告
fireworks2（烟花2.mp4）	0.349	SUSPICIOUS	medium	high	M7 high 不被降级

结论：V2 模型显著抑制烟花/强光 fire 误检（2.2~15 倍），真实火灾检出保留；联合链路 YOLO→M6→M7→Agent→Hybrid 全部运行成功，Fallback 与 M7 High 保护正常。

第十八章：V2.7 —— 最终闭环演示

使用 tools/v2_final_demo.py 以 V2 模型 + 真实视频跑完整闭环（烟火.mp4，conf=0.5）：

YOLO(V2) OK 576 帧 (skip=2)
M6 事件聚合 OK 8 个事件（代表事件 smoke=0.630）
M7 Rule Decision OK level=medium score=0.394
M9 事件日志 OK events.jsonl
DeepSeek Agent OK SUSPICIOUS / medium
Hybrid Final OK final=medium
M8 证据截图 OK 3 张代表帧

M10 报告 OK event.json / report.md / report.pdf
M11 GUI 展示 OK gui_agent_panel.png
FINAL_DEMO_RESULT: PASS

烟花2 闭环验证：生产 conf=0.5 + V2 模型下不再产生误报事件（fire 置信度 $0.482 < 0.5$ ）；即使强制形成事件，Agent 判 SUSPICIOUS、Hybrid Final 保持 HIGH。

第十九章：最终系统功能

- 图片检测：加载图片输出 fire/smoke 检测结果；
- 视频检测：实时/离线视频逐帧检测；
- 火灾事件识别：M6 聚合为 FireEvent（秒制时长、面积特征、增长趋势）；
- 规则风险判断：M7 输出 low/medium/high + score/confidence/reasons；
- LLM Agent 分析：DeepSeek 主动查询工具、解释规则、给出可能原因与建议；
- 历史 Memory：相似已结束事件检索，辅助证据；
- Hybrid 安全决策：融合规则与 Agent，M7 High 不可降级，可升级但进入人工复核；
- 截图：confirmed/peak/upgrade/final 证据归档；
- 日志：事件、决策、Agent、Memory、工具调用 JSONL 全程留痕（无 API Key）；
- 自动报告：M10 生成含 Agent Analysis 的 md/pdf；
- GUI：M11 展示 Rule / Agent / Memory / Hybrid Final 与事件历史。

第二十章：最终技术栈

类别	技术
语言	Python 3.11
视觉	OpenCV
检测	Ultralytics YOLO
模型（V1）	YOLO11n Baseline V1
模型（V2）	YOLO11n V2-15k
Agent	DeepSeek V4 Flash
Agent 协议	Tool Calling / JSON Output
决策	Rule Engine + Hybrid
Memory	Structured Event Retrieval（无 Embedding/Vector DB）
GUI	PyQt6 / Qt
报告	Markdown + PDF（reportlab）
日志	JSONL
测试	Python unittest
版本控制	Git（tag: v0.1.0-baseline; v0.2.0-agent 待封板）
GPU	NVIDIA RTX 4060 Laptop（CUDA）

第二十一章：项目测试与验收体系

数据审计 → Smoke Training → Baseline Training → 独立 Test
→ M6/M7 回归 → Agent Loop → Hybrid → Memory → M10 → M11 → 人工 GUI 验收

各阶段最终测试数量（全部来自实际运行记录）：

阶段	测试数
Phase 1	66
Phase 2	97
Phase 2.1	101
Phase 3-A	143
Phase 3-B	157
Phase 4-A	173
Phase 4-B	186
当前总计（Phase 5/6 后）	186

全部测试为 Mock / 离线，不消耗真实 API 额度；真实 API 通过独立冒烟脚本验证。

第二十二章：项目目前存在的问题

如实列出（不以「已知问题」包装为「全部解决」）：

1. fire 困难负样本不足（当前仅 66 张本地烟花负样本）；
2. 烟花强光仍存在部分误检（V2 已大幅降低，但 conf=0.25 下仍可能出现 fire 检出）；
3. 真实 ended 历史事件数量有限（约 29 条），Memory 实际召回有限；
4. 历史 event_id 存在重复，检索仅按 event_id 排除当前事件；
5. 日志置信度为 avg 而非 max，语义存在差异；
6. legacy duration 单位不确定时只能标记 unknown；
7. Agent 输出存在偶发 Schema 失败（已由 Fallback 兜底）；
8. Agent 实时延迟为秒级（4.5k~8.8k tokens / 7~18s），不适用于每帧；
9. 当前 Memory 为结构化检索，非向量语义检索。

第二十三章：后续优化路线

V2.1（GUI / 报告细节）

- Agent 完成后补刷最终报告（当前事件结束时若 Agent 未完成，报告先展示已有数据）；
- Memory 历史表区分 Not Used / Unavailable；
- 历史详情按事件自身数据完善展示。

V2 Model（模型优化）

- 扩充困难负样本：烟花/强光/车灯/路灯/云雾/蒸汽/夜间灯光；
- 视频分组数据划分（已落地 V2-15k，可继续扩大）；

- 更长训练（50~60 轮）或更大数据集（50k）；
- 必要时 YOLO11n → YOLO11s 以提升召回。

V3（未来方向，未实施）

- Embedding / Vector Memory;
- 更强 Agent Memory（跨事件推理）；
- 多模态视觉 Agent。

第二十四章：最终验收结论

FireGuardian V2 已完成:

- V1 核心视觉检测
- + 规则安全底座
- + DeepSeek Agent
- + Tool Calling
- + Agent Memory
- + Hybrid Decision
- + M10 Agent Report
- + M11 GUI

- 自动化测试 186/186 通过；
- 用户已完成最终人工 GUI 验收（按 Phase 4-B 人工验收清单），图片、视频、Agent、Memory、M10、M11 人工检查通过；
- 真实闭环演示（烟火.mp4）PASS；烟花2 强光误检显著下降且 M7 High 未被降级；
- 当前版本可以作为稳定 Demo 版本封存；Git 封板（Stage B: commit + v0.2.0-agent tag）按任务书后续执行。

附录 A：版本演进

版本	说明	状态
v0.1.0-baseline	FireGuardian V1 稳定基线（tag 已创建）	已完成
v0.2.0-agent	FireGuardian V2 Agent Stable Demo	Stage B 待封板

附录 B：测试报告索引（仅列真实存在文件）

tools/
dataset_audit.md
smoke_training_report.md
baseline_v1_training_report.md
baseline_v1_visual_audit.md
m6_m7_fix_report.md
v2_phase1_report.md
v2_phase2_report.md
v2_phase2_1_fix_record.md
v2_phase3_report.md
v2_phase3b_report.md
v2_phase4a_report.md
v2_phase4b_report.md

v2_phase5_report.md
v2_phase6_report.md
v2_final_demo_report.md
v2_conf_analysis.md

附录 C：重要测试视频

- me.mp4 (烟花/短时亮光)
- 测试视频/烟花1.mp4 (smoke 主导)
- 测试视频/烟花2.mp4 (强光误检风险, M7=high)
- 烟火.mp4 (真实火灾)

说明：测试视频不进入 Git 源码。


附录 D：模型版本

模型	用途	默认	SHA-256 (前 16 位)
smoke_v1_best.pt	V1 冒烟模型	否	-
baseline_v1_best.pt	V1 Baseline 最佳	否	5b84350ebdfaf489
models/best.pt	V1 生产默认 (config 默认加载)	是	-
models/v2_15k_best.pt	V2 模型 (Phase 5)	否 (可选切换)	9e674c156d8d638a

附录 E：关键截图索引

- GUI Agent Analysis 面板 (Phase 4-B, fireworks2 重点案例)：


tools/v2_phase4b_screenshots/fireworks2_agent_panel.png



GUI Agent Analysis 面板 (Phase 4-B: fireworks2)


- V2 闭环演示 GUI 面板 (烟火.mp4 主闭环)：

tools/v2_final_demo/event_FE-20260816205941-79e2a5/gui_agent_panel.png




V2 闭环演示 GUI 面板 (烟火.mp4)

- V1 评估 F1 曲线: runs/baseline_train/baseline_v1/eval_curves/f1_curve.png



V1 Baseline 评估 F1 曲线

- V2 评估 F1 曲线: runs/v2_model/v2_15k/eval_curves/f1_curve.png



V2-15k 评估 F1 曲线

本报告由 FireGuardian V2 各阶段真实测试与运行记录整理而成；所有指标均来自实际执行结果。